

# 航道对外服务智能体

当前阶段：需求分析与技术预研（初稿）

分析日期：2026-09-09

本项目拟建设一个面向船东企业、工程建设单位、设计院、沿江港航企业和社会公众的航道对外服务智能体。第一阶段以千问系列模型为核心，通过 RAG（检索增强生成）连接航道专业资料，先实现答案可追溯的知识问答；随后再接入实时航道数据和业务系统，逐步实现办事指引、航评咨询、事项进度查询和定向信息推送。

需求来源：本地原始资料 profile/对外服务智能体初步建设需求.docx，该目录不纳入版本库。

## 一句话结论

这个项目不能只做“把文档放进向量库后聊天”。完整需求至少包含四类能力：静态知识库、实时数据查询、政务事项流程和主动服务。建议先做一个范围可控、答案带出处的知识库问答 MVP，再逐步接入动态数据与业务流程。

## 需求分析

### 1. 航道专业知识库与公共服务名录

- 建设技术标准库、航道基础信息库、航评案例库和法规政策库。
- 建设公共服务名录，维护服务事项、办理条件、材料清单、办理时限、责任部门和联系方式。
- 将“知识查询”和“事项办理指引”关联起来。

### 2. 7×24 小时航道信息问答

- 支持自然语言问答、多轮对话、上下文理解和必要的追问。
- 覆盖航道尺度、水深、航标、航行通告、航道管制、水位、政策和办事信息。
- 记录问题、检索结果、用户反馈和热点主题，供知识库持续优化。

### 3. 公共服务解答

- 对法规、政策和技术标准进行检索、引用和通俗化解释。
- 为专用航标设置或调整、航评咨询等事项提供分步骤指引。
- 后续按用户类型和业务场景推送政策更新、标准修订及宣传内容。

### 4. 定制化涉航技术服务

- 根据桥梁、管线、码头等工程类型提供航评咨询。
- 接收项目初步方案，依据法规和标准生成辅助合规检查结果、相似案例和风险提示。
- 按船东企业、沿江港航企业和社会公众建立不同的服务内容与订阅规则。
- 对事项受理、审核和办结节点进行进度提醒。

能力边界

| 能力               | 正确实现方式                     | 不能只依赖什么       |
|------------------|----------------------------|---------------|
| 法规、标准、历史报告问答     | 文档解析、混合检索、重排、千问生成、原文引用     | 仅靠模型自身知识      |
| 水深、水位、气象、管制等实时信息 | 对接权威数据库或 API，并返回数据时间       | 定期上传的静态文件     |
| 办理条件和材料清单        | 结构化公共服务名录，并设置责任部门审核和版本生效时间 | 从长文中临时生成      |
| 审批进度查询和节点提醒      | 对接业务办理系统、用户身份和消息渠道         | 向量数据库         |
| 项目方案合规检查         | 文件解析、规则检索、结构化检查项和人工复核      | 让大模型直接作最终合规结论 |
| 定向政策推送           | 用户标签、订阅授权、规则引擎和消息发送能力      | 普通聊天会话        |

智能体应定位为查询、咨询和辅助判断工具。法规解释、合规检查和审批事项必须展示依据、文件版本和数据时间；高风险结果应交由业务人员复核，不能替代法定审批或专业结论。

现有资料的文件名分析

以下判断只依据目录和文件名，尚未检查各材料正文、扫描质量、重复情况或法律效力。

资料规模

除需求文档和系统隐藏文件外，profile 下共有 287 份候选知识资料：

| 目录              | 数量 | 从名称推断的用途                                       |
|-----------------|----|------------------------------------------------|
| 材料一/航道公共服务信息等   | 66 | 月度公共服务信息、维护尺度、养护计划、年度运行报告和碍航信息；同时包含动态或时效性较强的资料 |
| 材料一/法律法规等       | 73 | 国家及地方航道、水路运输、水上安全、采砂和岸线保护等法律法规                 |
| 材料一/规定等         | 54 | 办法、规则、管理规定、应急预案、办理及报告编制要求                      |
| 材料一/技术标准等（第一部分） | 30 | JTS 等航道、水运工程、航标、测量和通航条件评价标准                    |
| 材料二/技术标准等（第二部分） | 60 | GB、GB/T、JTS 等技术标准和指南，是第一部分标准资料的延续              |
| 目录清单            | 4  | 公共服务信息、法律法规、标准和规定的 Excel 清单，可作为资料台账或元数据初始化来源   |

候选资料格式包括 156 个 PDF、109 个 DOCX、17 个旧版 DOC、4 个 XLSX，以及 1 个缺少扩展名的文件。

适合建立的知识集合

不要沿用“材料一”和“材料二”作为最终知识库名称，建议按业务语义重组为：

- 1. technical\_standards：合并两部分技术标准，按标准号、名称、发布年份、状态和适用场景检索。

- 2. `laws_and_policies`：法律法规与管理规定，按效力层级、发布机关、地域、发布日期、生效日期和有效状态管理。
- 3. `channel_public_information`：公共服务信息、维护尺度、养护计划、运行报告和通告，重点管理航段及时间范围。
- 4. `service_catalog`：办事项、条件、材料、时限、责任部门、联系方式和流程节点，优先结构化存储。
- 5. `navigation_assessment_cases`：需求中要求的航评报告、审批意见和典型案例；现有文件名中未看到明确、完整的案例集合，需要另行补充。

从文件名发现的数据治理问题

- 公共服务资料覆盖2018—2026年，并同时存在年度、月度和计划类文件。检索时必须优先匹配航段、适用年月、发布日期和最新有效版本，不能把历史值当成当前值。
- 法规文件通常用日期后缀标识版本，但部分名称的日期为空，如 `福建省航道条例_.docx`。需要从正文或权威台账补齐发布日期、生效日期、修订状态和效力状态。
- 技术标准文件名包含+、序号、逗号及下载编号等噪声，标准号写法也不统一。入库前要规范化标题和标准编号，同时保留原始文件名。
- 存在旧版 `.doc` 文件，解析链路需要先转换为 `DOCX` 或 `PDF`。
- `2025 年度长江干线主航道养护尺度标准` 缺少扩展名，应先确认实际格式和文件完整性。
- `PDF` 可能包含扫描页、复杂表格和跨页表格。正式入库前必须进行可解析性检测，并为扫描件配置 `OCR` 和表格抽取。
- `Excel` 目录清单适合做台账入口，但未核对内容前不能默认它们与实际文件一一对应。

建议的文档元数据

每个文档至少保存以下字段：

```
document_id
title
original_filename
knowledge_collection
document_type
document_number
issuer
region
channel_section
project_type
publish_date
effective_date
expiry_date
validity_status
data_period
source_system
source_url
version
confidentiality_level
checksum
ingested_at
reviewed_by
```

法规、标准和公共服务信息应使用不同的切分策略。法规按章、条切分，技术标准按章节并保留表格标题，月度信息按航段和指标切分，办事指南则直接拆成结构化字段。每个文本片段必须保留文档、章节、页码或条款号，以便回答时引用原文。

## 初步技术方案



建议将模型服务、检索服务和业务系统连接器解耦。上层统一使用兼容 OpenAI 风格的模型接口，便于在千问不同型号、部署方式和后续升级之间切换，避免业务代码绑定某个具体模型。

## 千问模型策略

- 默认采用千问系列指令模型作为回答生成与工具调用模型。
- MVP 阶段可先使用已有千问 API 或实验室模型服务验证问答效果，避免模型部署阻塞知识库和评测工作。
- 私有化阶段计划使用昇腾 MindIE/CANN 推理栈，但不能根据显存总量直接决定模型。应先确认服务器操作系统、CPU 架构、Atlas 300I Duo 芯片与固件、CANN、MindIE、算子和目标千问版本的完整兼容矩阵。
- 精确模型型号、上下文长度、量化方式、并行策略和并发数由 PoC 实测确定。先比较一个中小参数模型和一个更高能力模型在准确率、首字延迟、吞吐、显存占用及稳定性上的结果。
- 向量模型和重排模型应独立选型，重点测试中文法规、标准号、航段名、数值和表格内容的召回能力，不要求与生成模型使用同一尺寸。

参考官方入口：[Qwen3](#)、[MindIE 安装与软硬件配套说明](#)。Qwen 官方给出了通过 MindIE 在昇腾 NPU 上部署的方向，MindIE 文档列出了 Atlas 300I Duo 的部署环境；具体模型是否支持当前服务器仍以最终选定版本的兼容性查询和现场验证为准。

建议的基础组件

| 模块       | 初步选择                       | 说明                          |
|----------|----------------------------|-----------------------------|
| 大模型      | 千问系列指令模型                   | 负责回答生成、问题改写、意图识别和工具调用       |
| 推理服务     | MindIE/CANN，MVP 可先接兼容 API  | 私有部署前先验证 Atlas 300I Duo 兼容性 |
| 文档处理     | PDF、DOCX、DOC、XLSX 解析 + OCR | 保留页码、标题层级、表格和来源信息           |
| 检索       | 关键词检索 + 向量检索 + 重排          | 标准号、法规名和精确数值不能只靠向量召回        |
| 元数据与业务数据 | 关系型数据库                     | 管理版本、时效、权限、服务事项和用户订阅        |
| 向量索引     | 选用支持元数据过滤的向量数据库            | 产品待结合现有技术栈和运维能力确定           |
| 接口层      | HTTP API + 流式输出            | 隔离模型、知识库和外部业务系统             |
| 观测与评测    | 请求日志、链路追踪、离线评测集            | 监测召回、引用、延迟、失败和用户反馈          |

实施顺序

阶段 0：补齐前置条件

- 确认首批服务对象、访问入口、内外网部署方式和身份认证方式。
- 获取数字航道、航行通告、水位气象、事项办理和消息推送系统的接口清单。
- 获取服务器实际 OS、驱动、固件、CANN、MindIE 和 npu-smi info 信息。
- 明确哪些资料可以对公众开放，哪些只允许内部用户访问。
- 由业务部门确定法规、标准、公共服务信息的权威来源和审核责任人。

阶段 1：知识库问答 MVP

建议先只做“静态资料问答”，完成一条可验证的最小闭环：

1. 从四类资料中各选一批代表性文件，覆盖文本 PDF、扫描 PDF、表格 PDF、DOCX、DOC 和 XLSX。
2. 建立资料台账，完成格式识别、OCR、正文与表格抽取、标题规范化和元数据补齐。
3. 实现分类型切分、关键词与向量混合检索、重排及来源引用。
4. 接入千问，要求回答仅依据检索结果；证据不足时明确拒答或请求补充信息。
5. 提供一个简单对话页面或 API，支持流式回答、多轮上下文和来源查看。
6. 建立业务评测集，覆盖精确查找、跨文档比较、历史与现行版本区分、数值问答、无答案拒答和提示注入攻击。
7. 由业务人员审核结果，根据失败案例调整解析、元数据、召回和提示词。

MVP 的交付物应包括：资料台账、入库流水线、可重复构建的索引、带引用的问答接口、基础对话页面、评测数据集和评测报告。

## 阶段 2：公共服务名录

- 将办事条件、材料、时限、部门和联系方式从文档整理为结构化数据。
- 实现按用户场景逐步追问，并生成办理清单。
- 对每项服务设置版本、生效时间、审核人和修改记录。

## 阶段 3：动态数据与业务系统

- 通过工具调用接入水深、水位、气象、航标、航行通告和航道管制等权威接口。
- 回答中明确数据来源和更新时间；接口失败时不得用历史知识冒充实时结果。
- 接入事项办理系统，实现进度查询与节点提醒。

## 阶段 4：定制化服务

- 建立用户标签、订阅、授权和退订机制。
- 实现政策更新、风险预警和服务简报的定向推送。
- 实现项目方案上传、文本抽取、检查项匹配、相似案例检索和人工复核工作台。
- 在业务审核后再生成对外宣传图文，避免模型未经复核直接发布。

## 你现在要做什么

按优先级完成以下工作即可启动项目：

1. 找业务负责人确认 MVP 是否先聚焦“法规、规定、技术标准和历史公共服务信息问答”。
2. 索取航评案例、公共服务事项完整名录，以及各动态业务系统的接口文档和样例数据。
3. 找运维导出服务器的软件环境和 NPU 信息，确认 Atlas 300I Duo 能运行的 MindIE 与千问组合。
4. 指定每类知识资料的审核人，确认公开范围、现行版本和更新流程。
5. 从现有资料中选取约 20—30 份代表性文档作为首批样本，不要一次性导入全部资料。
6. 与业务专家共同编写首批真实问题及标准答案，用它们选择模型、检索和切分方案。
7. 确认预期并发、响应时间、可用性、部署网络和日志留存要求，再确定生产架构。

## 待确认问题

- 系统最终面向公网、政务外网、内网，还是同时支持多个入口？
- 是否存在统一用户体系，是否需要实名、企业认证和分级授权？
- 哪些数据是实时数据，其权威接口、刷新频率和失败兜底规则是什么？
- 公共服务名录由哪个部门维护，是否已有结构化系统？
- 是否需要直接提交申请，还是第一期只提供材料和流程指引？
- 政策推送使用短信、微信、网站消息还是其他渠道？
- 上传的项目方案可能包含哪些敏感信息，保存多久，谁可以查看？
- 答案是否必须逐条引用到页码或法规条款，业务人员如何纠错和发布新版本？
- 目标并发、首字延迟、峰值请求量和故障恢复指标是多少？

- 千问模型必须完全离线部署，还是允许 MVP 阶段调用受控的云端 API？

## 初步验收指标

正式数值需要和业务方确认，至少应覆盖：

- 文档解析成功率、OCR 可读率和表格抽取正确率。
- 检索召回率、重排质量和无答案识别率。
- 回答事实准确率、引用正确率、现行版本识别率和数值准确率。
- 实时数据来源与更新时间展示完整率。
- 首字延迟、完整响应时间、吞吐、并发和服务可用性。
- 越权访问、敏感信息泄露、提示注入和恶意文件上传防护。
- 用户反馈闭环、知识更新时延和问题热点统计能力。

## 安全与质量要求

- 知识入库、模型服务和用户访问都要进行权限隔离。
- 对上传文件做扩展名、MIME、大小、病毒和恶意内容检查。
- 防止知识库文档或用户输入中的提示注入改变系统规则。
- 对回答保存问题、检索证据、模型版本、提示版本、工具调用和输出，便于审计。
- 动态数值必须带时间戳；历史资料必须标识数据期；失效法规 and 标准不得作为现行依据。
- 对外答案默认附来源。没有可靠证据时明确说明无法确认，不生成貌似确定的结论。
- 用户画像和主动推送必须取得授权，并提供退订与数据删除机制。

## 建议的仓库结构

当前仓库只有需求资料，开始开发后建议逐步整理为：

```
.
├── README.md
├── docs/          # 需求、架构、接口、数据字典和评测说明
├── data/
│   ├── raw/      # 原始资料，只读保存
│   ├── manifests/ # 文档台账与元数据
│   └── evals/     # 评测问题、标准答案和证据
├── src/
│   ├── api/      # 对话与管理 API
│   ├── agent/    # 智能体编排、提示词和工具调用
│   ├── ingestion/ # 解析、OCR、清洗、切分和入库
│   ├── retrieval/ # 混合检索、重排和引用
│   └── connectors/ # 数字航道及业务系统连接器
├── tests/        # 单元、集成、安全和离线评测
└── deploy/       # 容器、MindIE、环境配置和运维脚本
```

原始资料不建议直接提交到后续公开代码仓库；应根据数据权限放入受控存储，并仅在台账中保存受控引用。

## 现有服务器配置

### 黄河服务器 Huanghe 2280 V2

- 基本配置：Huanghe 2280 V2，12 × 3.5 英寸 HDD EXP，2U 机架；2 × Kunpeng 920 5220，32 Core @ 2.6 GHz；4 × GE。
- 电源：2 × 2000 W 交流电源模块。
- 内存：8 × DDR4 RDIMM 32 GB，288 pin，0.625 ns，3200 MHz，1.2 V，ECC。
- SATA 固态硬盘：4 × 3840 GB，SATA 6 Gb/s，读取密集型，2.5 英寸（3.5 英寸托架）。
- NVMe 固态硬盘：2 × 3840 GB，NVMe PCIe，读密集型，2.5 英寸（3.5 英寸托架）。
- RAID：1 × 8i RAID 标卡，PCIe 3.0 × 8，2 GB cache，支持 RAID 0/1/5/6/10/50/60、超级电容和边带管理。
- 网络：1 × 双端口 10 Gb SFP+ 以太网卡，PCIe 3.0 × 8，不含光模块。
- 光模块：2 × SFP+ 10G 多模模块，850 nm，0.3 km，LC。
- 推理卡：4 × Atlas 300I Duo，PCIe × 16，48 GB DDRX，150 W，单槽位，被动散热，Device ID D500。
- 机架附件：2U 静态滑轨套件。

硬件清单只能说明该服务器可用于昇腾推理预研，不能代替软件兼容性和模型性能验证。部署前还需要确认磁盘 RAID 规划、模型与索引容量、数据备份、10 Gb 网络连接、散热、电源、OS 版本以及全部昇腾软件版本。